

Proyecto Integrador — Minería de Datos 1

Análisis de usuarios de una plataforma de streaming

1. Contexto y objetivo

El proyecto aplica un proceso completo de análisis de datos sobre un dataset de usuarios de una plataforma de streaming: inspección inicial, limpieza justificada con evidencia, análisis exploratorio univariado/bivariado/multivariado y reducción de dimensionalidad mediante PCA. No incluye modelado predictivo. El objetivo es identificar qué variables explican el comportamiento de consumo y la elección de plan de suscripción.

2. Dataset y calidad inicial

El dataset original (streaming_users_dirty.json) contiene 8.160 registros con 8 columnas: user_id, age, subscription_plan, monthly_watch_time_mins, country, favorite_genre, last_login_date y customer_support_tickets. La inspección inicial detectó: filas y user_id duplicados, categorías escritas de forma inconsistente, valores imposibles (edades y tickets fuera de rango, consumos con valores sentinela), fechas en formatos mixtos o inválidas, y valores nulos en varias columnas.

3. Decisiones de limpieza y preparación

Cada decisión se tomó solo ante evidencia concreta de error, priorizando conservar el máximo de información posible:

Problema	Evidencia	Decisión
Filas duplicadas exactas	126 filas idénticas	Eliminadas
user_id duplicado con datos distintos	34 usuarios con estados conflictivos, sin marca de tiempo	Se conserva la primera aparición
Categorías inconsistentes	Variantes de escritura en 3 columnas categóricas	Estandarizadas a forma canónica
Fechas en formatos mixtos / inválidas	Formatos mezclados + 64 fechas imposibles (ej. 31/02) + 15 fechas futuras	Unificadas a fecha real; inválidas → nulo
Valores numéricos imposibles	Negativos y valores sentinela (ej. 99999 min, 150 tickets)	Valor puntual → nulo (se conserva la fila)

No se imputaron valores numéricos automáticamente en la limpieza general, para no fabricar información. El dataset final quedó con 8.000 filas (98.04% de retención). Detalle completo en logs/pipeline_log.csv y notebooks/02_calidad_y_limpieza.ipynb.

4. Hallazgos del análisis exploratorio

El consumo mensual promedio crece de forma escalonada según el plan: 597 min (Básico), 872 min (Estándar) y 1.140 min (Premium). En cambio, los tickets de soporte (~0.8 en los tres planes), la edad (correlación ≈ 0.004 con el consumo) y el país (distribución de planes prácticamente idéntica en los 7 países) no mostraron relación con el plan contratado. El consumo mensual resultó ser, por lejos, la variable más informativa del dataset.

5. Reducción de dimensionalidad (PCA)

Se aplicó PCA sobre las 3 variables numéricas (age, monthly_watch_time_mins, customer_support_tickets), escaladas con StandardScaler. Las 3 componentes explicaron una varianza casi idéntica (33.6%, 33.4%, 33.0%), confirmando que las variables originales ya eran casi independientes entre sí: PCA no logró reducir la dimensionalidad de forma efectiva en este caso. Aun así, la componente PC2 (dominada por el consumo) separó claramente a los usuarios por plan, reforzando el hallazgo principal del EDA.

6. Conclusiones y limitaciones

El consumo mensual de contenido es la variable que mejor caracteriza a los usuarios según su plan de suscripción; la edad, el país y los tickets de soporte no aportan una relación equivalente. Como limitaciones: la resolución de user_id duplicados con datos conflictivos no pudo verificarse contra una fuente de verdad; un pequeño grupo de edades muy bajas (0 y 4 años) quedó sin tratar como error por falta de una regla clara; y las variables disponibles son limitadas para explicar en profundidad el comportamiento del usuario. Como mejora futura, se podría incorporar información adicional (dispositivo, sesiones, motivo de baja) y una marca de tiempo de carga que permita resolver duplicados con mayor certeza.

7. Enlaces

Repositorio GitHub: (*completar enlace*) | Aplicación Streamlit: (*completar enlace*) | Notebooks: notebooks/01_inspeccion_inicial.ipynb a 05_conclusiones.ipynb | Log ETL: logs/pipeline_log.csv